

Gün 5 — Shannon Entropy Analizi ve Görselleştirme

Hedef

Dosya içindeki veri yoğunluğu farklarını Shannon entropy hesabıyla ortaya çıkarmak; Gün 3'te üretilen polyglot dosyalarda görsel bölgesi ile arkasına eklenmiş video bölgesi arasındaki entropy farkını grafik üzerinde görünür kılmak.

Yaklaşım

1. Blok bazlı Shannon entropy hesabı

Dosya sabit boyutlu bloklara (`--block-size` , varsayılan 256 bayt) bölünüyor. Her blok için, blok içindeki bayt değerlerinin frekans dağılımından klasik Shannon entropy formülü uygulanıyor:

$$H = -\sum p(x) \cdot \log_2(p(x)) \quad (x: 0-255 \text{ arası bayt değeri})$$

Sonuç, bayt başına 0-8 bit aralığında bir değer. 8'e yakın değerler "rastgele/sıkıştırılmış/yüksek yoğunluklu" veriyi, düşük değerler ise tekrarlayan/öngörülebilir veriyi (ör. düz renk alanları, header/padding) işaret ediyor.

2. Görsel/video sınırının grafiğe işlenmesi

Her blok bağımsız hesaplandığından, script ayrıca Gün 4'teki `detect_trailer.analyze()` fonksiyonunu içe aktararak dosyanın gizli video başlangıç offset'ini (varsa) buluyor ve bunu grafikte kırmızı kesikli dikey çizgi olarak işaretliyor. Dosya PNG/JPEG değilse veya trailer'da bilinen bir video imzası yoksa çizgi hiç çizilmiyor — bu da kod tekrarını önlerken (Gün 4 mantığının yeniden kullanılması) iki günün çıktısını tek grafikte birleştiriyor.

3. Görselleştirme ve dosya adlandırma

matplotlib ile `offset → entropy` çizgi grafiği çiziliyor, `Agg` backend kullanılarak GUI'siz (headless) ortamda da çalışması sağlandı. Çıktı dosya adı, iki farklı formattaki aynı köke sahip dosyalar (`sample.png` / `sample.jpg`) arasında çakışmayı önlemek için tam dosya adından türetiliyor (`entropy-sample.png.png` , `entropy-sample.jpg.png`) — geliştirme sırasında bu çakışma fark edilip düzeltildi.

Script: `scripts/entropy.py`

```
python scripts/entropy.py --file <dosya>
python scripts/entropy.py --file <dosya> --block-size 512 --output <çıktı.png>
python scripts/entropy.py --file <dosya> --json
```


Varsayılan çıktı: `docs/entropy-<dosya_adı>.png` . `--json` bayrağı, her bloğun `offset` , `size` ve `entropy` alanlarını ayrıca konsola yazdırıyor.

Test Sonuçları


Dosya	Blok sayısı	Sınır offset	Grafikte gözlem
<code>samples/polyglot.png</code>	15	217 (<code>0xD9</code>)	Sınırın hemen öncesinde/sonrasında belirgin entropy değişimi; video verisinin (H.264/MP4 konteyner) ~7 bit/bayt civarı yüksek ve görece düz seyrettiği bölge net ayırt ediliyor
<code>samples/polyglot.jpg</code>	19	1371 (<code>0x55B</code>)	Fark PNG'ye göre daha az belirgin — JPEG kendisi de zaten sıkıştırılmış olduğundan görsel bölgesi de yüksek entropili; yine de sınır civarında hafif bir düşüş/toparlanma gözlemleniyor
<code>samples/sample.png</code> (temiz)	1	tespit edilemedi	Sınır çizgisi yok (beklenen davranış)
<code>samples/sample.jpg</code> (temiz)	6	tespit edilemedi	Sınır çizgisi yok, entropy tüm dosya boyunca homojen yüksek (tipik sıkıştırılmış JPEG karakteristiği)

Üretilen grafikler: `docs/entropy-polyglot_png.png` , `docs/entropy-polyglot_jpg.jpg` , `docs/entropy-sample.png` , `docs/entropy-sample.jpg` .

Görsel: PNG polyglot (net ayırım)



Görsel: JPEG polyglot (daha zayıf ayırım)



Kabul Kriterleri — Durum

- [x] Üretilen entropy grafiğinde görsel/video geçiş noktası görsel olarak ayırt edilebiliyor (PNG'de net, JPEG'de daha zayıf ama gözlemlenebilir)
- [x] Grafik docs/ altına PNG olarak kaydedilebiliyor

Notlar / Riskler

- Plan'da öngörülen risk doğrulandı: **sıkıştırılmış görsellerde (JPEG) görsel/video ayrımı PNG'ye göre daha zordur**, çünkü JPEG'in kendisi DCT tabanlı sıkıştırma sonucu zaten yüksek entropili veri üretir; PNG ise sıkıştırmasız/az sıkıştırılmış olduğundan video verisiyle kontrastı daha belirgindir. Bu bulgu, tek başına entropy analizinin JPEG polyglot'larda yeterli bir sinyal olmayabileceğini, Gün 4'teki trailer/imza tespiti ile birlikte kullanılması gerektiğini destekliyor.
- Blok boyutu (`--block-size`) sonucu doğrudan etkiliyor: çok küçük bloklar (örn. 16 bayt) gürültülü/dalgalı bir grafik üretirken çok büyük bloklar (örn. 4096 bayt) sınırdaki geçişi bulanıklaştırabilir; 256 bayt varsayılan değeri bu projedeki küçük örnek dosyalar için dengeli bir çözünürlük sağladı.
- `find_boundary_offset()` , `detect_trailer.analyze()` 'ı çağırırken `ValueError / FileNotFoundError` yakalıyor; böylece PNG/JPEG olmayan bir dosya (ör. ham `.mp4`) `entropy.py` 'ye verildiğinde sınır çizgisi gösterilmeden grafik yine de üretiliyor (script çökmüyor).