

Gün 8 — Extraction (Unpolyglot) Fonksiyonu

Hedef

Görsel arkasına gizlenmiş MP4 video akışını orijinal görselden ayırıp bağımsız bir dosya olarak kaydeden `scripts/extract.py` script'ini yazmak; böylece Gün 4'te yalnızca *tespit* edilen gizli video, gerçekten oynatılabilir bir dosyaya dönüşsün ("unpolyglot").

Yaklaşım

1. Ayırma noktasının belirlenmesi — `detect_trailer.py` 'nin yeniden kullanımı

Gün 4'te yazılan `detect_trailer.analyze()` fonksiyonu zaten görselin gerçek bitiş offset'ini (`image_end_offset`) format-farkında bir şekilde (PNG IEND chunk zinciri / JPEG marker taraması) hesaplıyor. `extract.py` bu fonksiyonu doğrudan içe aktarıp çağırıyor — offset hesaplama mantığını tekrar yazmak yerine tek kaynaktan besleniyor:

```
from detect_trailer import analyze as analyze_trailer
...
trailer_info = analyze_trailer(path)
split_offset = trailer_info["image_end_offset"]
```

Gün 3'teki `make_polyglot.py` görseli ve videoyu **doğrudan concat** ettiği için (`image_bytes + video_bytes` , ara bayt yok), ayırma noktası olarak `image_end_offset` 'in kendisi kullanıldı — `detect_trailer` 'ın ayrı raporladığı `hidden_video_offset` (imza taramasının bulduğu konum) değil. İki değer bu projenin polyglot'larında pratikte örtüşür, ancak `image_end_offset` format parsing'inden geldiği için daha güvenilir ayırma noktasıdır; `hidden_video_offset` yalnızca *hangi imzanın bulunduğunu* raporlamak içindir.

2. Polyglot olmayan dosyalarda güvenli reddetme

`detect_trailer_info["polyglot_status"]` `False` ise (gizli video imzası yoksa) `extract()` hiçbir dosya yazmadan `ValueError` fırlatıyor; `detect_trailer.py` 'nin ürettiği

analysis_summary mesajı hataya zincirleniyor, böylece kullanıcı neden ayıklamanın reddedildiğini görüyor.

3. Çıktı dosyaları

- Video kısmı her zaman <output-dir>/<stem>_extracted.mp4 olarak yazılıyor (varsayılan output-dir: samples/extracted/ , zaten .gitignore 'da).
- --save-image bayrağı verilirse, görsel kısmı da doğrulama amaçlı <stem>_extracted_image.<png|jpg> olarak ayrıca kaydediliyor (planın "opsiyonel" olarak işaretlediği alt görev).
- Sonuçta size_match alanıyla dosyaBoyutu == görselBoyutu + videoBoyutu eşitliği doğrulanıp rapora ekleniyor.

Script: scripts/extract.py

```
python scripts/extract.py --file <polyglot dosya>
python scripts/extract.py --file <polyglot dosya> --save-image --json
python scripts/extract.py --file <polyglot dosya> --output-dir <dizin>
```

Çıktı alanları: file , file_size , image_format , split_offset , image_size , video_size , size_match , extracted_video_path , extracted_image_path .

Test Sonuçları

Dosya	Ayırma offset'i	Görsel boyutu	Video boyutu	Toplam eşleşiyor mu?	ffprobe
samples/polyglot_png.png	217 (0xD9)	217 bayt	3471 bayt	3688 = 217+3471 ✓	probe_score=100 , h264/64x64/2s ✓
samples/polyglot_jpg.jpg	1371 (0x55B)	1371 bayt	3471 bayt	4842 = 1371+3471 ✓	probe_score=100 , h264/64x64/2s ✓

Ayrıca `--save-image` ile ayıklanan görsel kısımları, `cmp` ile orijinal kaynak dosyalarla (`samples/sample.png` , `samples/sample.jpg`) **bayt-bayt aynı** çıktı (fark bulunamadı) — bu, ayırma noktasının (`image_end_offset`) doğru hesaplandığını ve concatenation'ın kayıpsız tersine çevrilebildiğini kanıtlıyor. `file` komutu da her iki ayıklanmış görseli doğru formatında (`PNG image data` , `JPEG image data`) tanıdı.

Negatif test — temiz (video içermeyen) bir dosyada script hiçbir çıktı dosyası üretmeden anlamlı bir hata ile reddediyor:

```
$ python scripts/extract.py --file samples/sample.jpg
Hata: 'samples/sample.jpg' bir polyglot dosya değil (gizli video imzası bulunamadı): EOF sonrası fazladan veri yok, dosya temiz.
$ echo $?
1
```

Örnek insan-okur çıktı (`samples/polyglot.png.png` , `--save-image` olmadan):

Dosya:	<code>samples/polyglot.png.png</code>
Dosya boyutu:	3688 bayt
Görsel formatı:	PNG
Ayırma offset'i:	217 (0xD9)
Görsel kısmı boyutu:	217 bayt
Video kısmı boyutu:	3471 bayt
Boyut tutarlılığı:	OK
Ayıklanan video:	<code>samples/extracted/polyglot.png_extracted.mp4</code>

Kabul Kriterleri — Durum

- [x] Ayıklanan `.mp4` dosyası `ffprobe` ile hatasız açılıyor (her iki örnekte de `probe_score=100` , h264/64x64/2sn/20 kare) ve bir video player'da oynatılabilir durumda
- [x] Ayıklama işlemi sonrası orijinal polyglot dosyanın boyutu = ayıklanan görsel boyutu + ayıklanan video boyutu (her iki örnekte de doğrulandı)
- [x] (Ek doğrulama) Ayıklanan görsel kısmı orijinal kaynak görselle bayt-bayt aynı (`cmp` farksız)
- [x] (Ek doğrulama) Polyglot olmayan bir dosyada script dosya yazmadan anlamlı hata ile çıkıyor (exit code 1)

Notlar / Riskler

- Yok (plan notu ile uyumlu). Ayırma mantığı, Gün 4'teki format-farkında offset hesaplamasına dayandığı için Gün 2'deki risklerin (gömülü EXIF thumbnail'inin sahte EOI 'si, JPEG bayt-stuffing) `extract.py` seviyesinde tekrar ele alınmasına gerek kalmadı — tek bir yerde (`detect_trailer.py`) çözülmüş bir problem burada yeniden kullanıldı.